



به نام خدا



دانشگاه تهران  
دانشکده مهندسی برق و کامپیوتر  
ماشین لرزینگ

تمرین ۴

نام و نام خانوادگی	محمد مشرقی
شماره دانشجویی	810199492
تاریخ ارسال گزارش	

## فهرست


۵.....	-۱
۵.....	۱
۶.....	۲
۷.....	۳
۸.....	۲
۸.....	۱
۸.....	۲
۸.....	۳
۹.....	۲
۹.....	۳
۹.....	۴
۱۰.....	۵
۱۱.....	۳
۱۲.....	۴
۱۲.....	۱
۱۲.....	۲
۱۳.....	Linear
۱۳.....	Poly
۱۳.....	RBF
۱۴.....	RBF dataset
۱۵.....	Poly dataset
۱۷.....	۴
۱۷.....	regularization hyperparameter

۱۸.....	gamma Hyperparameter
۲۰.....	تست مقادیر هایپرپارامتر روی RBF
۲۶.....	تست مقادیر هایپرپارامتر روی poly دیفالت درجه ۳
۳۲.....	تست مقادیر هایپرپارامتر روی linear
۳۵.....	5
۳۸.....	نتیجه گیری
۳۹.....	۶
۳۹.....	One vs all
۴۲.....	One vs one
۴۴.....	نتیجه کلی
۴۵.....	۵
۴۵.....	۱
۴۶.....	۲
۴۷.....	۳
۴۸.....	6
۵۰.....	7
۵۰.....	الف
۵۱.....	
۵۱.....	ب
۵۲.....	ب



$$(\mathbf{w} \cdot \mathbf{x}) + b = 0, \quad \mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}$$

می فهمیم که جهت قرار گیری خطوط یا صفحه طبق بردار  $\mathbf{w}$  انتخاب می شود و بردار hyperplane عمود بر صفحه  $\mathbf{w}$  است و مرز تصمیم گیریست و  $b$  هم افستی است که به آن می دهیم تا مکان صفحه مشخص شود.



۲. در صورت وجود نویز در داده‌ی آموزش، آیا روش SVM توانای تفکیک آن‌ها را دارد؟ (بررسی کنید که چطور تفکیک انجام می‌شود)

در سوال وقتی نویز نداشته باشیم از hard SVM استفاده می‌کنیم که محدوده مارجین آن کم است اما وقتی نویز بیفتد دیگر نمی‌تواند به خوبی جدا کند برا هم سراغ softsvm با اینکار مقداری خطا را می‌پذیریم و در عوض محدوده حاشیه رابیشتر می‌کنیم با اینکار بهتر می‌توانیم داده‌ها را جدا سازی کنیم و به خوبی جلو نویز گرفته میشود و در فرمول هزینه یه ترم اضافه می‌شود

$$\min \frac{1}{2} ||\mathbf{w}||^2 + C \sum_{i=1}^n \zeta_i$$



$$\text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \zeta_i \quad \forall i = 1, \dots, n, \quad \zeta_i \geq 0$$

۳. مفهوم کلی کرنل را بیان کنید. فرض کنید از دو کرنل چند جمله‌ای درجه دو زیر برای تعریف طبقه‌بندی SVM استفاده شده است. کدام یک از طبقه‌بندها حاشیه بزرگ‌تری را نتیجه می‌دهد؟ چرا؟

$$\varphi_1 = [x, x^2]^T$$

$$\varphi_2 = [2x, 2x^2]^T$$

کرنل به رابطه ریاضی است که با استفاده از آن می‌توان فضای ویژگی داده را بیشتر کنیم و نتیجتاً باعث می‌شود با الگوریتم‌های خطی یا غیر خطی راحت‌تر داده‌ها را جدا کنیم. با استفاده از کرنل درست می‌توان روش را بهینه کرد و نتایج بهتری بدست آورد



دومی چون فاصله بین دو نقطه را بیشتر می‌کند. در نتیجه حاشیه آنها بیشتر و بزرگتر می‌شود.

12 Sep. 2017 ■ ۲۱ ذی الحجه ۱۴۳۸ ■ شهر یور ۲۱ به شنبه ۲

2-1)

$$K(x, y) = \exp\left(-\frac{\|x-y\|^2}{\sigma^2}\right)$$

$$= \exp\left(-\frac{x^T x - x^T y - y^T x + y^T y}{\sigma^2}\right)$$

$$= \exp\left(-\frac{\|x\|^2 - (x^T y + y^T x) + \|y\|^2}{\sigma^2}\right)$$

$$= \underbrace{\exp\left(-\frac{\|x\|^2}{\sigma^2}\right)}_{F(x)} \underbrace{\exp\left(-\frac{\|y\|^2}{\sigma^2}\right)}_{F(y)} \underbrace{\exp\left(\frac{2x^T y}{\sigma^2}\right)}_{K(x, y)}$$

بالوکته

حال چون سه ترم برابر باشند پس کرنل محقق است

✓



$$2.2) K(x, y) = b K_1(x, y) + a K_2(x, y)$$

$$\left( \forall g: \iint g(x) K(x, y) g(y) dx dy \geq 0 \right) \xrightarrow{\text{قانون}} P^T K P$$

2

$$= \iint b g(x) K_1(x, y) g(y) dx dy \quad (1)$$

$$+ a \iint g(x) K_2(x, y) g(y) dx dy \quad (2)$$

در عبارت بالا در نرم داریم که این در همیشه باید مثبت باشد

$$\left\{ \begin{array}{ll} a, b > 0 & \checkmark \\ a, b < 0 & \times \\ a > 0, b < 0 & \\ b > 0, a < 0 & \end{array} \right\} \text{ نامعین}$$

3

$$2.3) K(x, y) = F(x) F(y) \quad P^T K P \geq 0$$

$$P^T K P = \sum_{i=1}^n \sum_{j=1}^n P_i P_j F(x_i) F(x_j) = \left( \sum_{i=1}^n P_i F(x_i) \right)^2 \geq 0$$

چون توان  $\geq$  دارد همواره بزرگتر یا مساوی صفر است

4

$$2.4) P^T K P \geq 0$$

$$K_1(x, y) = \langle F(x), F(y) \rangle \quad \checkmark$$

$$K(x, y) = K_1(g(x), g(y)) = \langle F(g(x)), F(g(y)) \rangle$$

$$2.5) K(m, j) = K_1(m, j) \times K_2(m, j)$$

$$= \sum_{i=1}^m a_i(m) a_i(j) \times \sum_{j=1}^m b_j(m) b_j(j)$$

$$= \sum_{j=1}^m \sum_{i=1}^m \underbrace{a_i(m) b_j(m)}_{c_{ij}(m)} \underbrace{a_j(j) b_j(j)}_{c_{ij}(j)}$$

$$= \langle C(m)^T, C(j) \rangle \quad \checkmark$$

$$1 - P^T K P \geq 0$$

$$2 - \text{if } K \text{ is symmetric}$$

$$K(m, j) = K(j, m)$$

در عبارت بالا  $a_i(m)$  و  $b_j(m)$  را می توانیم به صورت  $a_i$  و  $b_j$  بنویسیم

چنانچه تابع Cost function برای Soft margin SVM به صورت زیر تعریف شود، نشان دهید که آیا اینکار می تواند تبدیل به یک مسئله class-separable شود؟


$$\frac{1}{2} \|w\|^2 + \frac{c}{2} \sum_{i=1}^N \varepsilon^2$$

بله در روش svm می توان با انجام اینکار و ضریب دهی به مسئله class separable تبدیل کرد

که با توجه به مقدار نهایی عبارت از طریق فرمول  $(\mathbf{w} \cdot \mathbf{x}) + b = 0, \quad \mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}$

اگر مثبت شود برای یه کلاس و اگر منفی شود یک کلاس دیگر است بدست می آید و می توان جدا

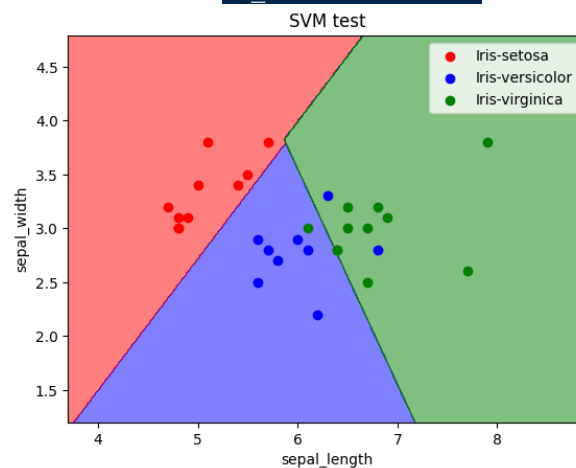
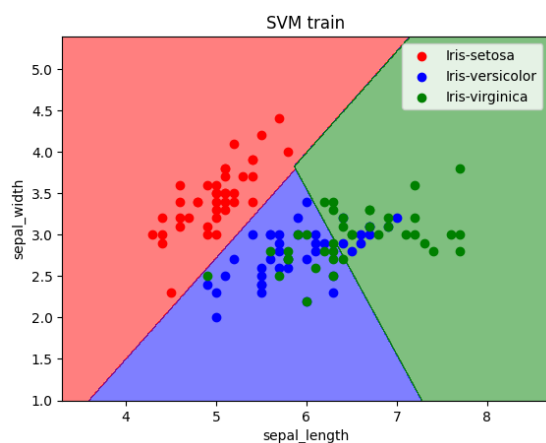
کرد



confusion matrix :

```
[[10  0  0]
 [ 0  7  2]
 [ 0  1 10]]
```

accuracy score = 0.900 precision score = 0.903 recall score = 0.896  
f1\_score = 0.898


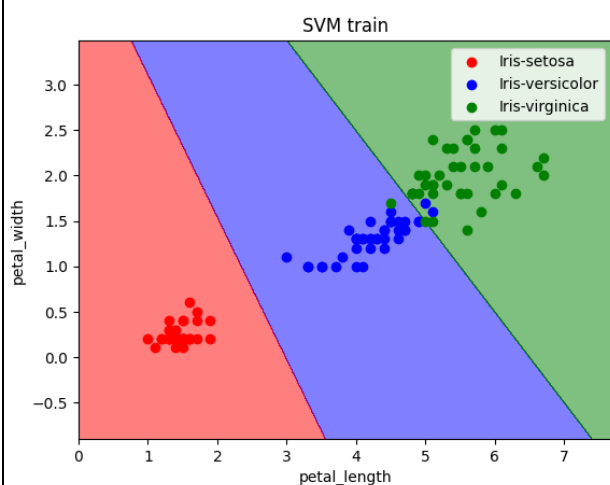


می بینیم که داده ها اصلا به خوبی جدا نشدن و فیچر های بدی داریم

confusion matrix :

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```

accuracy score = 1.000 precision score = 1.000 recall score = 1.000  
f1\_score = 1.000



با توجه به نتایج می بینیم که این مدل ویژگی خیلی بهتر بوده است

### Linear

کرنل خطی که به آن "غیر کرنل" نیز گفته می شود، کرنل خطی ساده ترین کرنل از همه کرنل ها است. وقتی از این کرنل استفاده می شود، داده ها از لحاظ فنی به ابعاد بالاتر نمایش داده نمی شوند، بنابراین فقط حاصل ضرب درونی  $x$  و  $y$  با یک عبارت ثابت اختیاری  $c$  است.


مزیت کرنل خطی این است که فوق العاده ساده است و فقط عبارت ثابت  $c$  را به عنوان پارامتر دارد. کرنل خطی معمولاً در مجموعه داده هایی با مقادیر زیادی ویژگی استفاده می شود، زیرا افزایش ابعاد در این مجموعه داده ها لزوماً تفکیک پذیری را بهبود نمی بخشد.

### Poly

بر خلاف کرنل خطی، کرنل چند جمله ای شامل گرفتن محصول داخلی از فضای ابعاد بالاتر است. با اینکار محاسبات بیشتر می شود و پارامتر های بیشتری را برای کنترل کردن داریم در عکس پایین ۳ پارامتر برای کنترل کردن داریم تا کاری کنیم برازش خوبی داشته باشیم و اورفیت نشود. بیشتر وقتی استفاده می شود که می فهمیم داده ها با چند جمله ای بهتر جدا می شوند.

### RBF

کرنل تابع پایه شعاعی (RBF) رایج ترین کرنل مورد استفاده در SVM است. به عنوان معادله کرنل تابع پایه شعاعی تعریف می شود که در آن  $\gamma$  یک پارامتر آزاد است که میزان تأثیر دو نقطه را بر یکدیگر مقیاس می کند. بر خلاف کرنل چند جمله ای که به  $d$  بعد اضافی نگاه می کند، RBF به تعداد نامتناهی



ابعاد گسترش می یابد. این به دلیل گسترش نمایی است.

Linear Kernel:  $K(X, Y) = X^T Y$

Polynomial kernel:  $K(X, Y) = (\gamma \cdot X^T Y + r)^d, \gamma > 0$

Radial basis function (RBF) Kernel:  $K(X, Y) = \exp(\|X - Y\|^2 / 2\sigma^2)$  which in simple form can be written as  $\exp(-\gamma \cdot \|X - Y\|^2), \gamma > 0$

Sigmoid Kernel:  $K(X, Y) = \tanh(\gamma \cdot X^T Y + r)$  which is similar to the sigmoid function in logistic regression.



Here  $r$ ,  $d$ , and  $\gamma$  are kernel parameters.

## RBF datatest

در این مسائل گاما ۰.۸ است.

```
[[10  0  0]
 [ 0  7  2]
 [ 0  1 10]]
```


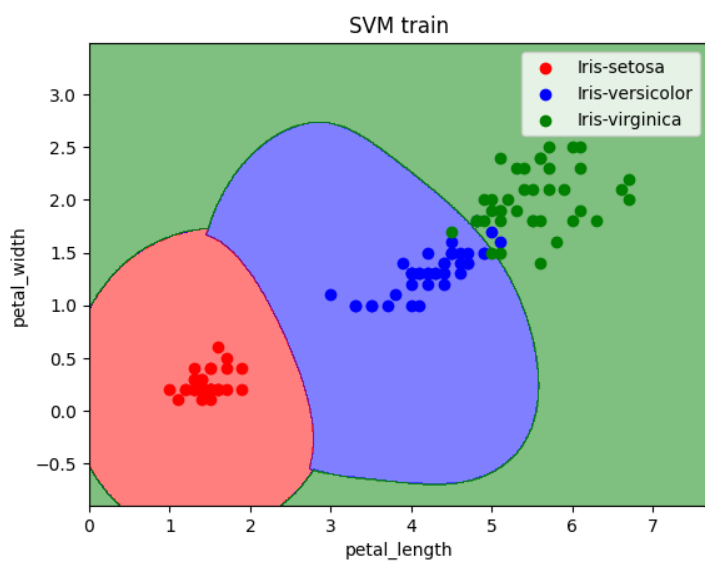
```
accuracy_score = 0.900    precision_score = 0.903    recall_score
= 0.896    f1_score = 0.898
```



confusion matrix :

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```

```
accuracy_score = 1.000    precision_score = 1.000    recall_score
= 1.000    f1_score = 1.000
```



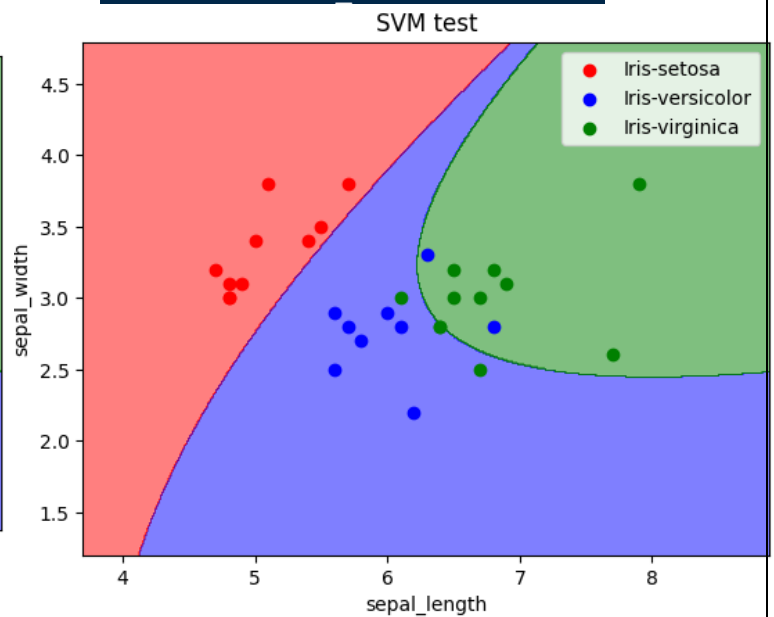
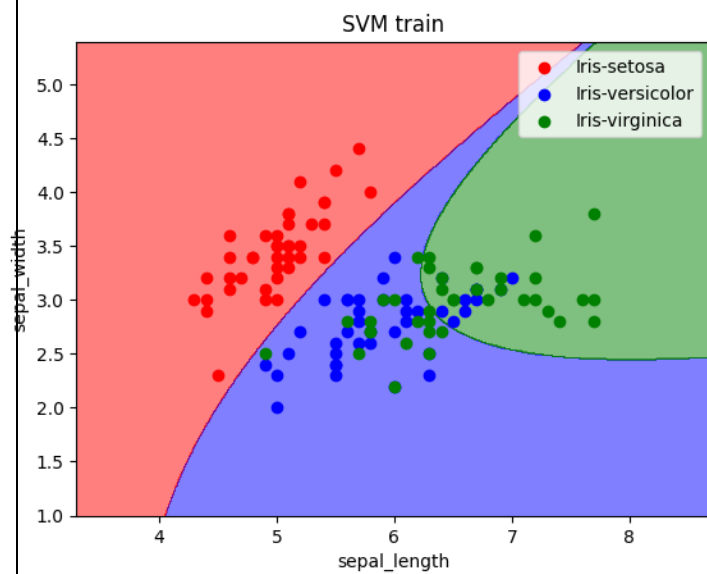
## Poly dataset

گاما ۰.۸ و درجه سه هست

confusion matrix :

```
[[10  0  0]
 [ 0  7  2]
 [ 0  4  7]]
```



accuracy\_score = 0.800    precision\_score = 0.805    recall\_score  
= 0.805    f1\_score = 0.800



confusion matrix :

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```

accuracy\_score = 1.000    precision\_score = 1.000    recall\_score  
= 1.000    f1\_score = 1.000




در نتایج فقط بخش sepal در چند جمله ای نتایج بدتر شد آن هم به دلیل درجه و بقیه بخش ها نتایج عوض شد و همانطور که می تونید ببینید مرز جدا کنندگیشونم تغییر کرده که این به دلیل خاصیت آن کرنل هستش




### regularization hyperparameter

پارامتر  $C$ : یک ترم ثابت مثبت است که توسط کاربر تعیین می شود و حاشیه امن (Margin) را کنترل می کند. و نسبت آن عکس اندازه حاشیه امن است.



- **$C$  بزرگ:** اگر مقدار بزرگی داشته باشد در نتیجه آن قیدهای مسئله بهینه سازی SVM شدید می شوند و اگر خیلی خیلی بزرگ باشد، مسئله بهینه سازی شبیه Hard Margin می شود. یعنی خطای طبقه بندی باید صفر باشد! که منظور همون overfit هستش.
- **$C$  متوسط:** اگر مقدار متوسط و حد معمولی داشته باشد در نتیجه آن شدت قیدهای مسئله بهینه سازی SVM کمتر می شود و به مدل اجازه میدهد مقداری خطا داشته باشد (ولی خطای حداقل نه خیلی زیاد) و همین باعث میشود که مرز مناسبی برای مسئله طبقه بندی پیدا کند.
- **$C$  کوچک:** اگر مقدار کوچکی داشته باشد در نتیجه آن شدت قیدهای مسئله بهینه سازی SVM خیلی کمتر می شود و به مدل اجازه میدهد خطای زیادی داشته باشد که در نتیجه آن ممکن است مدل به داده های پرت (outlier) حساس شود و در نتیجه مرز مناسبی بدست نیاید. مقدار  $C$  نباید خیلی کوچک باشد!




### **:gamma Hyperparameter**

در مورد کرنل RBF یا Poly مفید است. وقتی هسته شما خطی باشد هیچ نقشی ندارد. با توجه به اینکه ما می خواهیم یک تابع پیچیده را تحقق بخشیم،


گاما اساساً فاصله تأثیرگذاری یک نقطه تمرین را کنترل می کند.

- مقادیر پایین گاما نشان دهنده یک شعاع شباهت زیاد است که منجر به گروه بندی نقاط بیشتر با هم می شود. یعنی باعث می شود داده های آموزشی دور تر هم اثر گذار باشند و در پیدا کردن خط جدایی دو کلاس تأثیر بگذارند و اگر گاما خیلی پایین باشد احتمالاً دچار underfitting می شویم.
- برای مقادیر بالای گاما، نقاط باید بسیار نزدیک به هم باشند تا در یک گروه در نظر گرفته شوند. در این حالت فقط داده های مرزی مشارکتشون بیشتر میشه و ما بیشتر طبق اونها می سنجیم در این صورت ممکنه دچار overfitting شویم



#### **High Gamma**

- only near points are considered.




#### **Low Gamma**


- far away points are also considered

در کل داریم:


$\gamma=10^{-1}, C=10^{-2}$




$\gamma=10^0, C=10^{-2}$




$\gamma=10^1, C=10^{-2}$




$\gamma=10^{-1}, C=10^0$




$\gamma=10^0, C=10^0$




$\gamma=10^1, C=10^0$




$\gamma=10^{-1}, C=10^2$



$\gamma=10^0, C=10^2$



$\gamma=10^1, C=10^2$




## تست مقادیر هایپر پارمتر روی RBF


تاثیر C

گاما ۰.۸ و  $C = 100$

```
confusion matrix :  
[[10  0  0]  
 [ 0  7  2]  
 [ 0  1 10]]  
accuracy_score = 0.900  precision_score = 0.903  recall_score  
= 0.896  f1_score = 0.898
```



```
confusion matrix :  
[[10  0  0]  
 [ 0  6  3]  
 [ 0  1 10]]  
accuracy_score = 0.867  precision_score = 0.875  recall_score  
= 0.859  f1_score = 0.861
```




گاما ۰.۸ و  $C = 10$

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy_score = 1.000    precision_score = 1.000    recall_score
= 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  7  2]
 [ 0  1 10]]
```

```
accuracy_score = 0.900    precision_score = 0.903    recall_score
= 0.896    f1_score = 0.898
```




گاما ۰.۸ و  $C = 0.5$

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy score = 1.000    precision score = 1.000    recall score
= 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  7  2]
 [ 0  1 10]]
```

```
accuracy score = 0.900    precision score = 0.903    recall score
= 0.896    f1_score = 0.898
```




با توجه به مقادیر مختلف  $c$  می بینیم که با زیاد شدنش باعث overfitt شدن میشه و باید در رنج مشخصی باشه


تأثير گاما

گاما ۲ و  $C = 1$

```
confusion matrix :  
[[10  0  0]  
 [ 0  9  0]  
 [ 0  0 11]]  
accuracy_score = 1.000  precision_score = 1.000  recall_score  
= 1.000  f1_score = 1.000
```



```
confusion matrix :  
[[10  0  0]  
 [ 0  7  2]  
 [ 0  0 11]]  
accuracy_score = 0.933  precision_score = 0.949  recall_score  
= 0.926  f1_score = 0.931
```




گاما ۱۰ و  $c=1$

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy_score = 1.000    precision_score = 1.000    recall_score
                        = 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  8  1]
 [ 0  4  7]]
```

```
accuracy_score = 0.833    precision_score = 0.847    recall_score
                        = 0.842    f1_score = 0.833
```







گاما 100 و  $c=1$

confusion matrix :

```
[[10  0  0]
 [ 0  7  2]
 [ 0  0 11]]
```



```
accuracy_score = 0.933  precision_score = 0.949  recall_score
= 0.926  f1_score = 0.931
```



confusion matrix :

```
[[9 1 0]
 [0 7 2]
 [0 7 4]]
```

```
accuracy_score = 0.667  precision_score = 0.711  recall_score
= 0.680  f1_score = 0.667
```



با توجه به نتایج هرچی گاما بیشتر باشد overfitt و هرچی کمتر underfit که قشنگ و واضح می توان


دید

### تست مقادیر هایپر پارمتر روی poly دیفالت درجه ۳


تاثیر C

گاما ۰.۸ و C = 100

```
confusion matrix :  
[[10  0  0]  
 [ 0  8  1]  
 [ 0  0 11]]  
accuracy_score = 0.967 precision_score = 0.972 recall_score  
= 0.963 f1_score = 0.966
```



```
confusion matrix :  
[[10  0  0]  
 [ 0  7  2]  
 [ 0  1 10]]  
accuracy_score = 0.900 precision_score = 0.903 recall_score  
= 0.896 f1_score = 0.898
```




گاما ۰.۸ و  $C=1$

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy_score = 1.000    precision_score = 1.000    recall_score
                        = 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  7  2]
 [ 0  4  7]]
```

```
accuracy_score = 0.800    precision_score = 0.805    recall_score
                        = 0.805    f1_score = 0.800
```




گاما ۰.۸ و  $C = 0.1$

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy_score = 1.000    precision_score = 1.000    recall score
= 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  7  2]
 [ 0  1 10]]
```

```
accuracy_score = 0.900    precision_score = 0.903    recall score
= 0.896    f1_score = 0.898
```




با توجه به نتایج طبق توضیحات گفته بودیم چه اتفاقی می افتد


تأثير گاما

گاما ۰.۱ و  $C = 1$

```
confusion matrix :  
[[10  0  0]  
 [ 0  9  0]  
 [ 0  0 11]]  
accuracy_score = 1.000  precision_score = 1.000  recall_score  
= 1.000  f1_score = 1.000
```



```
confusion matrix :  
[[10  0  0]  
 [ 0  7  2]  
 [ 0  3  8]]  
accuracy_score = 0.833  precision_score = 0.833  recall_score  
= 0.835  f1_score = 0.833
```




گاما ۱۰۰ و  $C = 1$

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy_score = 1.000    precision_score = 1.000    recall score
                        = 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  7  2]
 [ 0  4  7]]
```

```
accuracy_score = 0.800    precision_score = 0.805    recall score
                        = 0.805    f1_score = 0.800
```




گاما ۱۰ و  $C = 1$

confusion matrix :

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy score = 1.000    precision score = 1.000    recall score
                        = 1.000    f1_score = 1.000
```



confusion matrix :

```
[[10  0  0]
 [ 0  7  2]
 [ 0  3  8]]
```

```
accuracy score = 0.833    precision score = 0.833    recall score
                        = 0.835    f1_score = 0.833
```




با توجه به نتایج طبق توضیحات گفته بودیم چه اتفاقی می افتد

## تست مقادیر هایپر پارمتر روی linear


تاثیر C در این بخش گاما نداریم

C = 1000

```
confusion matrix :  
[[10  0  0]  
 [ 0  9  0]  
 [ 0  0 11]]  
accuracy_score = 1.000    precision_score = 1.000    recall_score  
= 1.000    f1 score = 1.000
```



```
confusion matrix :  
[[10  0  0]  
 [ 0  7  2]  
 [ 0  1 10]]  
accuracy_score = 0.900    precision_score = 0.903    recall_score  
= 0.896    f1 score = 0.898
```






C = 0.01

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  1 10]]
```


```
accuracy_score = 0.967    precision_score = 0.967    recall_score
= 0.970    f1_score = 0.967
```



```
confusion matrix :
```

```
[[ 0 10  0]
 [ 0  9  0]
 [ 0 11  0]]
```

```
accuracy_score = 0.300    precision_score = 0.100    recall_score
= 0.333    f1_score = 0.154
```




C = 1

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```


```
accuracy_score = 1.000    precision_score = 1.000    recall_score
= 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  7  2]
 [ 0  1 10]]
```

```
accuracy_score = 0.900    precision_score = 0.903    recall_score
= 0.896    f1_score = 0.898
```



با توجه به نتایج نباید هم زیاد باشه هم کوچیک باشه

```

grid_parameters_rbf = {'kernel': ['rbf'], 'gamma': [10, 1, 0.1, 0.01, 0.001,
0.0001], 'C': [0.1, 1, 10, 100, 1000]}
grid_parameters_linear = {'kernel': ['linear'], 'C': [0.1, 1, 10, 100, 1000]}
grid_parameters_poly = {'kernel': ['poly'], 'gamma': [10, 1, 0.1, 0.01, 0.001,
0.0001], 'C': [0.1, 1, 10, 100, 1000]
, 'degree': [2, 3, 4]}

```

باتوجه به مقادیر برای خروجی RBF داریم:

```

for petal features :
best parameter : {'C': 100, 'gamma': 10, 'kernel': 'rbf'}
report:

```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	10
1	1.00	0.89	0.94	9
2	0.92	1.00	0.96	11
accuracy			0.97	30
macro avg	0.97	0.96	0.97	30
weighted avg	0.97	0.97	0.97	30

```

for sepal features :
best parameter : {'C': 1000, 'gamma': 0.01, 'kernel': 'rbf'}
report:

```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	10
1	0.64	0.78	0.70	9
2	0.78	0.64	0.70	11
accuracy			0.80	30
macro avg	0.80	0.80	0.80	30
weighted avg	0.81	0.80	0.80	30

باتوجه به مقادیر برای خروجی poly داریم:

```
for petal features :  
best parameter :  
{'C': 0.1, 'degree': 3, 'gamma': 10, 'kernel': 'poly'}  
report:
```

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

0	1.00	1.00	1.00	10
1	1.00	1.00	1.00	9
2	1.00	1.00	1.00	11

accuracy			1.00	30
macro avg	1.00	1.00	1.00	30
weighted avg	1.00	1.00	1.00	30

```
for sepal features :  
best parameter :  
{'C': 0.1, 'degree': 1, 'gamma': 1, 'kernel': 'poly'}  
report:
```

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

0	1.00	1.00	1.00	10
1	0.88	0.78	0.82	9
2	0.83	0.91	0.87	11

accuracy			0.90	30	
macro avg	0.90	0.90	0.90	30	
weighted avg		0.90	0.90	0.90	30

باتوجه به مقادیر برای خروجی linear داریم:

```
for petal features :  
best parameter :  
{'C': 100, 'kernel': 'linear'}  
report:
```

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

0	1.00	1.00	1.00	10
1	1.00	1.00	1.00	9
2	1.00	1.00	1.00	11

accuracy			1.00	30
macro avg	1.00	1.00	1.00	30
weighted avg	1.00	1.00	1.00	30

```
for sepal features :  
best parameter :  
{'C': 0.1, 'kernel': 'linear'}  
report:
```

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

0	1.00	1.00	1.00	10
1	0.88	0.78	0.82	9
2	0.83	0.91	0.87	11

accuracy			0.90	30	
macro avg	0.90	0.90	0.90	30	
weighted avg		0.90	0.90	0.90	30

## نتیجه گیری

باتوجه به نتایج بهترین گزینه برا طبقه بندی آنها همان **خطی** است البته به دلیل کم بودن داده ها مشخص نیست اما اگر تعداد داده بیشتر بود نتایجی میتوانست روش دیگری را بهتر نشان دهد

## One vs all


RBF

باتوجه به نتایج بخش قبل برای sepal گاما 0.01 و c=1000 و برای petal گاما 10 و c=100

confusion matrix :

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```

```
accuracy_score = 1.000    precision_score = 1.000    recall_score
= 1.000    f1_score = 1.000
```



confusion matrix :

```
[[10  0  0]
 [ 0  7  2]
 [ 0  4  7]]
```



```
accuracy score = 0.800    precision score = 0.805    recall score
= 0.805    f1_score = 0.800
```

اگر می بینید نتایج فرق کرده به این دلیل که داده های تست و ترین با بخش ۵ فرق داشته

Poly

باتوجه به نتایج بخش قبل برای sepal گاما 0.1 و  $c=0.1$  و برای petal گاما 10 و  $c=0.1$

```
confusion matrix :  
[[10  0  0]  
 [ 0  8  1]  
 [ 0  0 11]]  
accuracy_score = 0.967    precision_score = 0.972    recall_score  
= 0.963    f1_score = 0.966
```



```
confusion matrix :  
[[10  0  0]  
 [ 0  7  2]  
 [ 0  3  8]]  
accuracy_score = 0.833    precision_score = 0.833    recall_score  
= 0.835    f1_score = 0.833
```

در اینجا هم می بینیم که سپال برای خطی بهتر بود و اینجا ضعف دارد چون در صورت سوال نوشته



درجه سه



## Linear

باتوجه به نتایج بخش قبل برای  $c=0.1$  sepal و  $c=0.1$  petal

```
confusion matrix :  
[[10  0  0]  
 [ 0  3  6]  
 [ 0  0 11]]  
accuracy score = 0.800  precision score = 0.882  recall score  
= 0.778  f1_score = 0.762
```



```
confusion matrix :  
[[10  0  0]  
 [ 0  6  3]  
 [ 0  0 11]]  
accuracy score = 0.900  precision score = 0.929  recall score  
= 0.889  f1_score = 0.893
```

می بینیم که داده های آبی وسطی بیشترین ضرر رو کردن و محدودشون از بقیه کمتر شده

## One vs one



*RBF*

باتوجه به نتایج بخش قبل برای sepal گاما 0.01 و c=1000 و برای petal گاما 10 و c=100

confusion matrix :

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```

```
accuracy_score = 1.000    precision_score = 1.000    recall_score
= 1.000    f1_score = 1.000
```



confusion matrix :

```
[[10  0  0]
 [ 0  7  2]
 [ 0  3  8]]
```



```
accuracy_score = 0.833    precision_score = 0.833    recall_score
= 0.835    f1_score = 0.833
```

باتوجه به نتایج بخش قبل برای sepal گاما 0.1 و  $c=0.1$  و برای petal گاما 10  $c=0.1$

confusion matrix :

```
[[10  0  0]
 [ 0  8  1]
 [ 0  0 11]]
```

accuracy\_score = 0.967    precision\_score = 0.972    recall\_score  
= 0.963    f1\_score = 0.966



confusion matrix :

```
[[10  0  0]
 [ 0  7  2]
 [ 0  4  7]]
```

accuracy\_score = 0.800    precision\_score = 0.805    recall\_score  
= 0.805    f1\_score = 0.800

در اینجا هم می بینیم که سپال برای خطی بهتر بود و اینجا ضعف دارد چون در صورت سوال نوشته

درجه سه



## Linear

باتوجه به نتایج بخش قبل برای  $c=0.1$  sepal و برای  $c=0.1$  petal

```
confusion matrix :
```

```
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```

```
accuracy_score = 1.000    precision_score = 1.000    recall_score
= 1.000    f1_score = 1.000
```



```
confusion matrix :
```

```
[[10  0  0]
 [ 0  7  2]
 [ 0  1 10]]
```

```
accuracy score = 0.900    precision_score = 0.903    recall_score
= 0.896    f1_score = 0.898
```

## نتیجه کلی

با توجه به نتایج فک می کنم که برای قسمت آبی (گل وسطی) در روش one vs all کمتر ناحیه هست

اما در روش one vs one مرز تصمیم گیریش بیشتر میشه و نتایج هم بهتر است.

5) 1)

$$\| \theta(x) - \theta(y) \|^2 = \| \theta(x) \|^2 + \| \theta(y) \|^2 + 2 \theta^T(x) \theta(y)$$

$$\left. \begin{aligned} \| \theta(x) \|^2 &= \theta^T(x) \theta(x) = K(x, x) \leq 1 \\ \| \theta(y) \|^2 &\leq K(y, y) \leq 1 \end{aligned} \right\} *$$

$$\Rightarrow \| \theta(x) - \theta(y) \|^2 \leq 1 + 1 - 2 \theta^T(x) \theta(y)$$

$$= 2 - 2 e^{(-\frac{1}{2} \|x-y\|^2)} \quad \left\{ \begin{array}{l} \rightarrow \\ \rightarrow \end{array} \right.$$

$$\|x-y\|^2 > 0 \Rightarrow e^{(-\frac{1}{2} \|x-y\|^2)} > 0$$

$$2 - 2 e^{(-\frac{1}{2} \|x-y\|^2)} < 2 \quad \text{منه ياتي}$$

$$\| \theta(x) - \theta(y) \|^2 < 2 \quad \text{منه ياتي} \quad \checkmark$$

28Aug.2017

۶ ذی الحجه ۱۴۳۸

۶

۱۳۹۶  
شهریور  
دوشنبه

$$5.2) \quad |C(n, y)|^2 = (n^T y + 1)^2 = (n^T y)^2 + 1 + 2 n^T y$$

$$= \left( \sum_{i=1}^n n_i y_i \right)^2 + 2 \sum_{i=1}^n n_i y_i + 1$$

$$= \underbrace{\sum_{i=1}^n \sum_{j=1}^n (n_i n_j y_i y_j)}_{\textcircled{1}} + 2 \underbrace{\sum_{i=1}^n n_i y_i}_{\textcircled{3}} + \underbrace{1}_{\textcircled{4}}$$

$$\underbrace{\sum_{i=1}^n n_i^2 y_i^2}_{\textcircled{1}} + \underbrace{2 \sum_{i \neq j} n_i n_j y_i y_j}_{\textcircled{2}}$$

$$\textcircled{1} \Rightarrow (n_1^2, n_2^2, \dots, n_n^2)$$


$$\textcircled{2} \Rightarrow (\underbrace{n_1 n_2, n_1 n_3, \dots, n_1 n_n}_{n_1}, \underbrace{n_2 n_3, \dots, n_2 n_n}_{n_2}, \dots, n_{n-1} n_n)$$

$$\textcircled{3} \Rightarrow (n_1, n_2, \dots, n_n)$$

$$\textcircled{4} \Rightarrow (1)$$

$$\cdot \text{تقریباً} \Rightarrow \binom{n+2}{2} = \frac{(n+2)(n+1)}{2}$$

باتوجه به عکس تعداد داده های لازم برای دو دسته سه تا هست که می تونید ببینید



و این تعداد ممکنه بیشتر بشه اما کمتر ۳ نمی تونه بشه برا همین اگه یه داده نامعلوم دیگه اضافه کنیم

ممکنه همین ۳ بمونه یا حتی به تعداد SV برسه

$$6) 1) N=5$$

$$P(\text{صحيح}) = P(\text{خطأ}) = \frac{1}{2}$$

$$P(\text{error}) = P(\text{error} | \text{خطأ}) P(\text{خطأ})$$

$$+ P(\text{error} | \text{صحيح}) P(\text{صحيح})$$

$$= (P(\text{error} | \text{خطأ}) + P(\text{error} | \text{صحيح})) \cancel{P(\text{خطأ}) + P(\text{صحيح})}$$

$$= \underbrace{P(\text{error} | \text{خطأ})}_{①} + \underbrace{P(\text{error} | \text{صحيح})}_{②} \cdot \frac{1}{2}$$

$$① = \binom{5}{2} (0.5)^3 (0.4)^2 + \binom{5}{1} (0.5)^4 (0.4)^1 +$$

$$\binom{5}{0} (0.5)^5$$

$$= 0.48125$$

$$① = ②$$

$$P(\text{error}) = \frac{1}{2} (0.48125 + 0.48125) = 0.48125$$

$$P(\text{true}) = 1 - P(\text{error}) = 0.51875$$



2) N29

$$P(\text{error} | \text{در}) = P(\text{error} | \text{چپ})$$

$$= \binom{9}{0} (0.51)^0 + \binom{9}{1} (0.51)^1 (0.4)^8 + \binom{9}{2} (0.51)^2 (0.4)^7 + \binom{9}{3} (0.51)^3 (0.4)^6 + \binom{9}{4} (0.51)^4 (0.4)^5 + \binom{9}{5} (0.51)^5 (0.4)^4 + \binom{9}{6} (0.51)^6 (0.4)^3 + \binom{9}{7} (0.51)^7 (0.4)^2 + \binom{9}{8} (0.51)^8 (0.4)^1 + \binom{9}{9} (0.51)^9 (0.4)^0 \approx 0.524$$

$$P(\text{error}) = 1 - P(\text{error}) = 0.476$$

3- دقت بهمت 100 حاصل کنه چون تعداد که بیشتره دقت کمتره

و دقت بالایی رو

$$P(\text{error} | \text{چپ}) = P(\text{error} | \text{در})$$


$$= \binom{5}{0} (0.5)^0 + \dots + \binom{5}{5} (0.5)^5 = 0.5$$

$$P(\text{true}) = 1 - 0.5 = 0.5$$

با توجه به نتایج می فهمیم که اگر دقت طبقه بندی  $\frac{1}{2}$  باشد با افزایش تعداد

طبقات دقت ثابت می ماند و دقت تایید فرایند در

## الف



نتیجه خروجی نهایی به شکل رو به رو هست همینطور که می بینید هر کدام یک مشکلی دارد

برای مثال linear خیلی سادس و خطای آن زیاد

و برای poly با افزایش position level خیلی خوب همگام می شود و خطای کمی دارد اما ابتدای position level مقادیر درآمد منفی است که اصلا ایده آل نیست

برای RBF می بینیم مقادیر به خیلی خیلی خوب فیت شدن اما آخرین داده که خیلی بزرگ هست رو نتونسته به خوبی پیش بینی کنه

در کل RBF بهترین عملکرد رو داره که البته با تنظیم هایپر پارامتر ها میشه همشون رو بهتر کرد

```
rbf value :
[[ 73474.15615697]
 [ 70786.94584626]
 [ 88213.00902103]
 [108254.98574956]
 [122574.52250599]
 [145503.10688572]
 [209410.23132923]
 [330606.89204569]
 [471671.95587315]
 [557821.75899897]]
linear value :
[[-21802.18980308]
 [ 21598.9053814 ]
 [ 65000.00056589]
 [108401.09575037]
 [151802.19093486]
 [195203.28611934]
 [238604.38130383]
 [282005.47648831]
 [325406.5716728 ]
 [368807.66685728]]
poly value :
```

```
[368807.66685728]]
poly value :
[[-406153.33381986]
 [ -90097.02410228]
 [ 88401.09900247]
 [ 168643.37452662]
 [ 189932.14150242]
 [ 191569.7389621 ]
 [ 212858.50593789]
 [ 293100.78146205]
 [ 471598.9045668 ]
 [ 787655.21428438]]
real value :
[[ 45000.]
 [ 50000.]
 [ 60000.]
 [ 80000.]
 [ 110000.]
 [ 150000.]
 [ 200000.]
 [ 300000.]
 [ 500000.]
 [1000000.]]
```

ب

در این مسیر بعضی از داده که تعریف نشده بودن را حذف بعضی داده ها که رنج قیمت یک شب را صفر بود را حذف کردیم

سپس نرمالایز کردیم و ترین RBF با مقادیر دیفالت داریم :

خروجی نهایی

```
SVR Training MSE: 0.6605444862777878  
SVR Training R2 Score: -0.4248320147706788
```

فایل مورد نظر پیوست شد