



به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر
ماشین لرزینگ

تمرین 5

نام و نام خانوادگی	محمد مشرقی
شماره دانشجویی	810199492
تاریخ ارسال گزارش	

فهرست

۳.....	۱-.....
۳.....	الف.....
۴.....	ب.....
۵.....	2.....
۶.....	3.....
۶.....	الف.....
۸.....	ب.....
۹.....	4.....
۱۰.....	ب.....
۱۱.....	5.....
۱۱.....	الف.....
۱۵.....	ب.....
۱۸.....	6.....
۲۰.....	ب.....


الف

الف) نمایش محور اول و دوم PCA برای داده‌هایی که در شکل نمایش داده شده‌اند. آیا نوع برچسب داده‌ها در انتخاب محورهای PCA موثر است؟ چرا؟ (۵ نمره)


خیر

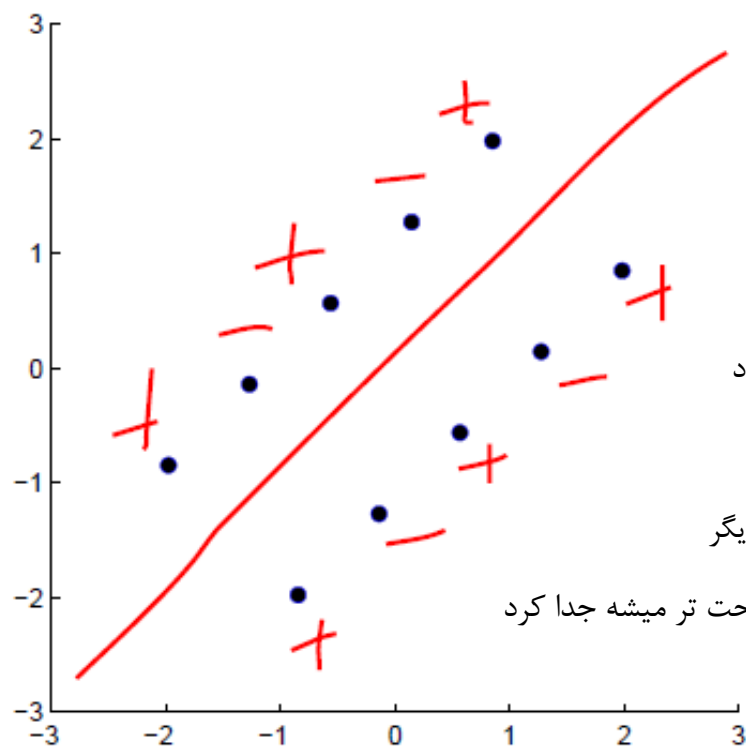
در یادگیری ماشین، PCA (تجزیه مؤلفه‌های اصلی) یک تکنیک بدون ناظر (unsupervised) برای کاهش ابعاد معمولاً استفاده می‌شود که برای استخراج ویژگی و تجسم داده به کار می‌رود. در فرآیند محاسبات PCA، برچسب‌ها یا اطلاعات کلاس مستقیماً در نظر گرفته نمی‌شوند.

در PCA داده به نحوی کاهش بعد پیدا می‌کنند که بیشترین واریانس ممکن رو داشته باشند.



ث





ب

در اینجا


دو بعدی نمی توان مسیر بهینه ای پیدا کرد

و اگر خطی ترسیم کنه هر دو خط دارند

در یک بعدی چون نقاط مثبت روی هم دیگر

و نقاط منفی هم روی یکدیگر می افتند راحت تر میشه جدا کرد

و جدایی دقیق میشود



در اینجا

در دو بعد هر کدام رو می توان با یک خطی بدست

آورد و دقت صد درصد گرفت

اما در یک بعدی چون داده های مثبت و منفی

رو هم قرار می گیرند اصلا قابل تشخیص نیست و

بدرد نمی خورد

$$Q_2 \quad S_1 = \sum_{i=1}^n (y_{i1} - m_1) \Rightarrow S_1^2 = \sum_{i=1}^n (y_{i1} - m_1)^2 = \sum_{i=1}^n y_{i1}^2 + m_1^2 - 2m_1 y_{i1}$$

$$\Rightarrow S_1^2 = \sum_{i=1}^n y_{i1}^2 + m_1^2 n - 2m_1 \sum_{i=1}^n y_{i1}$$

$$\boxed{\sum_{i=1}^n y_{i1}^2 = S_1^2 + m_1^2 n_1} \quad , \quad \boxed{\sum_{i=1}^n y_{i2}^2 = S_2^2 + m_2^2 n_2} \quad \text{نیز به روش مشابه}$$

$$J = \frac{1}{n_1 n_2} \sum \sum (y_{i1} - y_{j2})^2 = \frac{1}{n_1 n_2} \sum \sum (y_{i1}^2 + y_{j2}^2 - 2y_{i1} y_{j2})$$

$$= \frac{1}{n_1 n_2} \sum \left[n_2 y_{i1}^2 + S_2^2 + n_2 m_2^2 - 2y_{i1} n_2 m_2 \right]$$

$$= \frac{1}{n_1 n_2} \sum \left[n_2 y_{i1}^2 + n_2 m_1^2 + n_1 S_2^2 + n_1 m_2^2 - 2n_2 m_2 y_{i1} \right]$$

$$= \frac{1}{n_1} \frac{S_1^2 + m_1^2 n_1}{n_1} + \frac{1}{n_2} \frac{S_2^2 + m_2^2 n_2}{n_2} - 2m_1 m_2$$

$$= \frac{1}{n_1} S_1^2 + \frac{1}{n_2} S_2^2 + [m_1 - m_2]^2 \quad \checkmark$$

الف

$$a) \quad P(n) = \frac{\lambda^n e^{-\lambda}}{n!}$$

$$\hat{\lambda} = \arg \max_{\lambda} E \left[\sum_{i=1}^n \log p(n_i, z_i | \lambda) \right]$$

$$p(n, \lambda) = \sum_{k=1}^K \alpha_k c(n | \lambda_k) ; \sum_{k=1}^K \alpha_k = 1$$

$$D = \{n_1, \dots, n_n\} \quad \xrightarrow{\text{one-hot encoder}} \quad Z = \begin{bmatrix} 0 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}_{n \times K} \quad \Rightarrow p(n_i, z_i | \lambda) = \prod_{k=1}^K (\alpha_k c(n_i | \lambda_k))^{z_{ik}}$$

$$L(\lambda) = \log p(D, H | \lambda) = \sum_{i=1}^n \log p(n_i, z_i | \lambda) = \sum_{i=1}^n \sum_{k=1}^K z_{ik} (\log(\alpha_k) + \log c(n_i | \lambda_k))$$

$$= \sum_{i=1}^n \sum_{k=1}^K z_{ik} (\log(\alpha_k) + \log c(n_i | \lambda_k))$$

$$\Rightarrow E_Z[L(\lambda)] = \sum_{i=1}^n \sum_{k=1}^K E[z_{ik}] (\log(\alpha_k) + \log c(n_i | \lambda_k))$$

$$E_{z_i | n_i} [z_{ik}] = E[z_{ik} | n_i] = P(z_{ik} = 1 | n_i, \lambda^+) = \frac{P(n_i | z_{ik} = 1, \lambda^+)}{P(n_i | \lambda^+)} = \frac{c(n_i | \lambda_k^+) \alpha_k^+}{\sum_{k=1}^K \alpha_k^+ c(n_i | \lambda_k^+)} = \delta_{ik}^+$$

$$\arg \max_{\lambda} \sum_{i=1}^n \sum_{k=1}^K \gamma_{ik}^+ (\log \alpha_k + \log C(\lambda | \lambda_k))$$

$$s.t. \sum_{k=1}^K \alpha_k = 1$$

$$\Rightarrow Q(\lambda) = \sum_{i=1}^n \sum_{k=1}^K \gamma_{ik}^+ (\log \alpha_k + \log C(\lambda | \lambda_k)) - n \left(\sum_{k=1}^K \alpha_k - 1 \right)$$

for α_j

$$\Rightarrow \frac{\partial Q(\lambda)}{\partial \alpha_j} = \sum_{i=1}^n \frac{\gamma_{ij}^+}{\alpha_j} - n \Rightarrow \alpha_j = \frac{\sum_{i=1}^n \gamma_{ij}^+}{n}$$

for λ_j

$$\Rightarrow \sum_{k=1}^K \alpha_k \frac{\sum_{i=1}^n \sum_{j=1}^J \gamma_{ij}^+}{n} = 1 \Rightarrow M = \sum_{k=1}^K \sum_{i=1}^n \gamma_{ik}^+ \Rightarrow \boxed{M = \sum_{i=1}^n \sum_{k=1}^K \gamma_{ik}^+}$$

$$\Rightarrow \alpha_j = \frac{\sum_{i=1}^n \gamma_{ij}^+}{\sum_{k=1}^K \sum_{i=1}^n \gamma_{ik}^+} = \frac{\sum_{i=1}^n \gamma_{ij}^+}{n} \Rightarrow \boxed{\hat{\alpha}_j = \frac{\sum_{i=1}^n \gamma_{ij}^+}{n}}$$

$$\frac{\partial Q(\lambda)}{\partial \lambda_j} = \sum_{i=1}^n \gamma_{ij}^+ \left(\frac{m_i}{\lambda_j} - 1 \right) = 0 \Rightarrow \boxed{\hat{\lambda}_j = \frac{\sum_{i=1}^n \gamma_{ij}^+ m_i}{\sum_{i=1}^n \gamma_{ij}^+}}$$

3) b)

$$C = X^T X = \sum_{i=1}^n n_i n_i^T$$

sample covar: $\frac{1}{n} \sum_{i=1}^n n_i n_i^T$

PCA: $\max_P P^T C P \Rightarrow L(P) = P^T C P - \lambda (\|P\|_2^2 - 1)$
 $\lambda, + \frac{1}{2} \|P\|_2^2$

$\nabla_P L(P) = 0 \Rightarrow 2CP - 2\lambda P = 0 \Rightarrow \boxed{CP = \lambda P}$

مقدار درجه

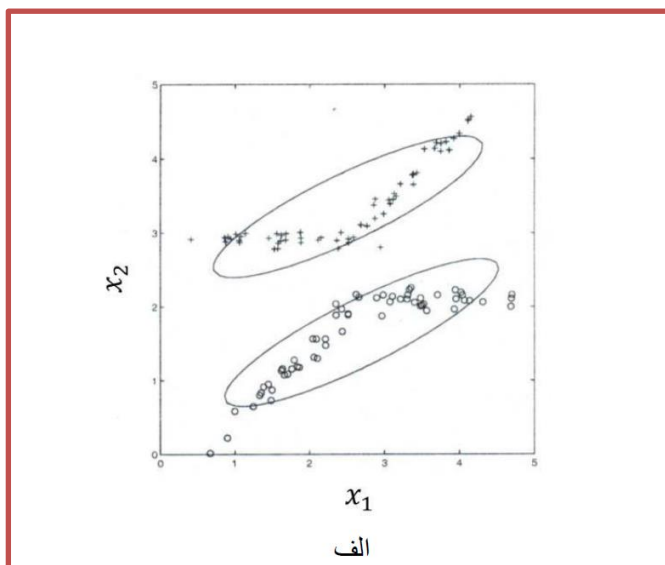

$\text{Var}(z) = P^T C P \xrightarrow{P_1} \text{Var}(z) = P_1^T (\lambda) P_1 = \lambda_1 P_1^T P_1 = \lambda_1 \|P_1\|_2^2 = \lambda_1$

مال و بیان می کنیم


$\underbrace{\lambda_1 \|P_1\|_2^2}_{=1}$

$\boxed{\text{Var}(z) = \lambda_1}$

الف) فرض کنید دو مدل زیر نتیجه اعمال الگوریتم EM و استفاده از Gaussian Mixture Model باشد، با ذکر دلیل توضیح دهید کدام یک از مدل‌های زیر مناسب‌تر است (۵ نمره)




گزینه الف بهتر است چون در ب کلی ناحیه در بر دارد که در آن داده نیست و هاپر پارامتر آن درست ست نشده منظور این است که در ب کلی ناحیه هست که احتمال میره در آن داده ای باشد اما نیست در حالی که در الف این جور نواحی خیلی خیلی کمتر است.




ب

با ذکر دلیل توضیح دهید کدام یک از موارد زیر خروجی اولین گام الگوریتم EM و استفاده از Gaussian Mixture Model خواهد بود. (۵ نمره)



ب



الف

خروجی بعدی الف خواهد بود چون در روش gaussian mixture model دنبال اضافه کردن نزدیک ترین داده به داده های خود میل می کند که به فرم خود نزدیک تر است که این مثال نقضی برای ب هستش چون داده های رو جمع اوری کرده که خیلی خیلی از مرکز شروع ابتدایی فاصله داشته


الف

ابتدا داده ها رو می گیریم و تعداد و فیچر آن را در میاریم

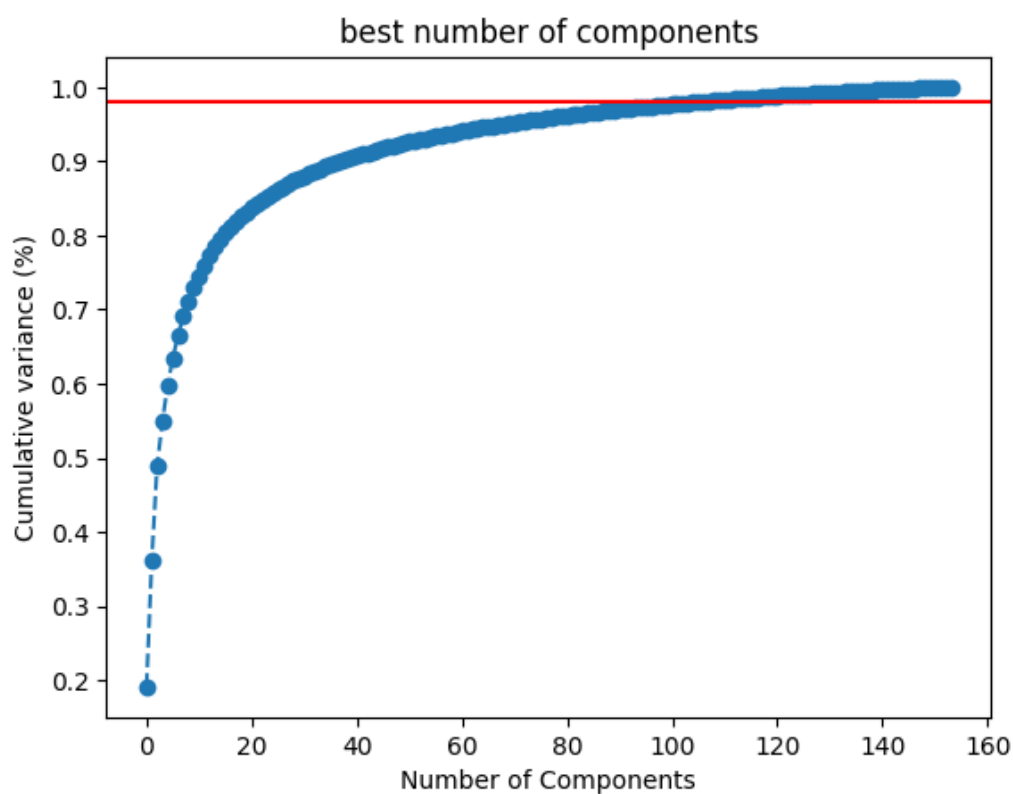
samples = 154
feature = 65536

سپس با PCA از ۱۵۴ فضا می بریم و مقایسه می کنیم

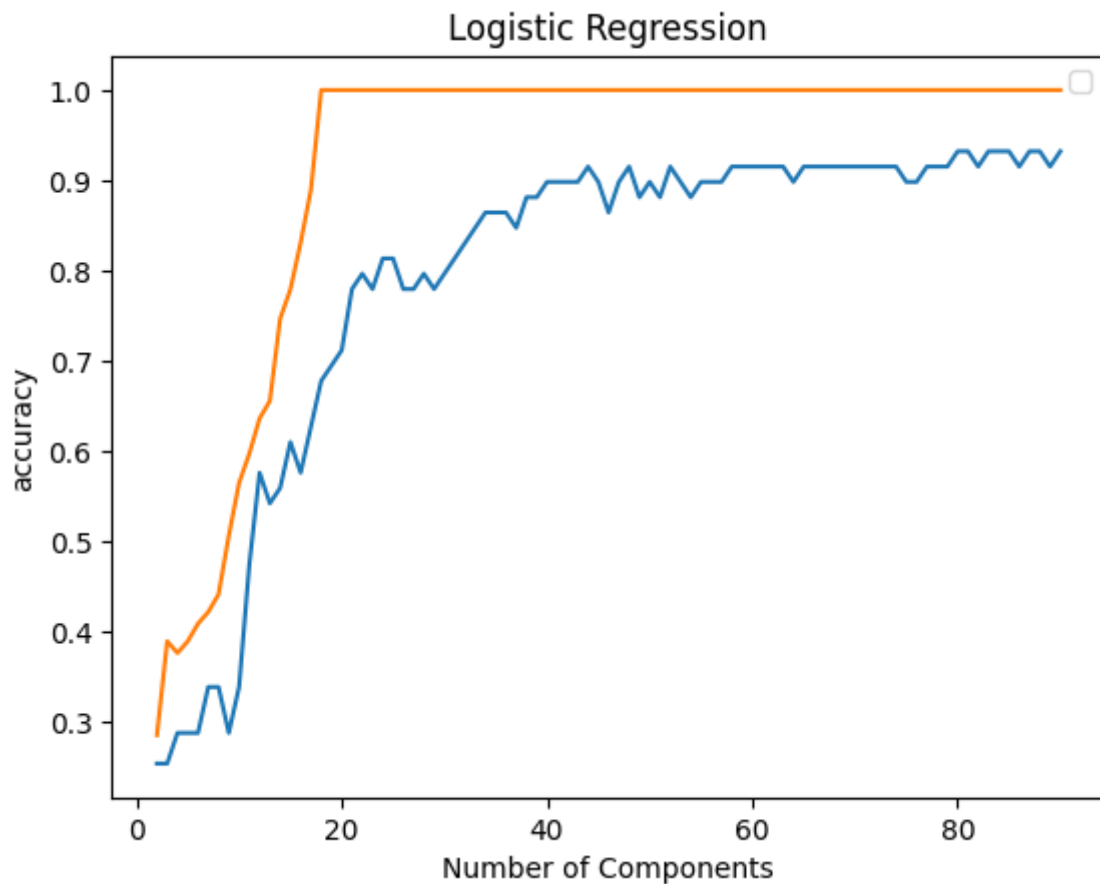
حال با توجه به عکس نقطه زانویی را در می یابیم :



Elbow Point = 16




برای اینکه بفهمیم بهترین تعداد کامپوننت چند تاست می توان با جمع کردن آن و گذاشتن یک حد
بهترین آن را بیابیم با توجه به شکل بالا حد ما 0.98 بود که در نتیجه برای آن ۱۰۰ تا کامپوننت نیاز
است.



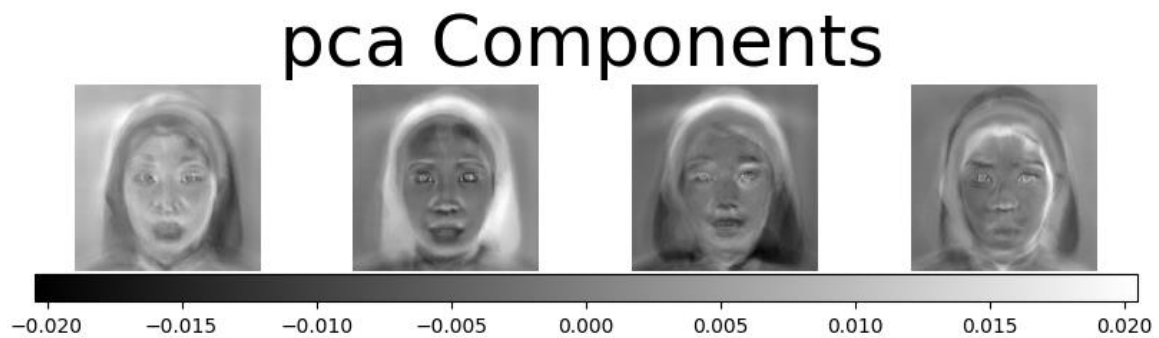
می بینیم که حتی با لاجستیک رگرشن با بیشتر شدن تعداد کامپوننت دقت بالا می رود

ب


حال با ۱۵۴ کامپوننت تصاویر داریم: pca Components



۴ تا اول



۴ تا آخر



با توجه به دو عکس می بینیم که مقادیر ویژه اول بزرگتر از آخری ها هستن و جزئیات بیشتری معلوم است چون واریانس بزرگتری دارند و جزئیات بیشتر واضح اند چون پراکندگی بیشتری دارد اما ۴ تا آخر نمیتوان به خوبی تفاوت را دید و جزئیات خیلی کمی را نشر می دهند. و پراکندگی کمتر دارد

ب

ماتریس پراکندگی درون کلاسی :

```
[ [ 514 448 448 ... 439 372 379 ]
[ 448 3723 6467 ... 10278 4314 664 ]
[ 448 6467 35431 ... 46530 13256 2456 ]
...
[ 439 10278 46530 ... 18310882 6260804 530248 ]
[ 372 4314 13256 ... 6260804 5045140 573847 ]
[ 379 664 2456 ... 530248 573847 258841 ] ]
```

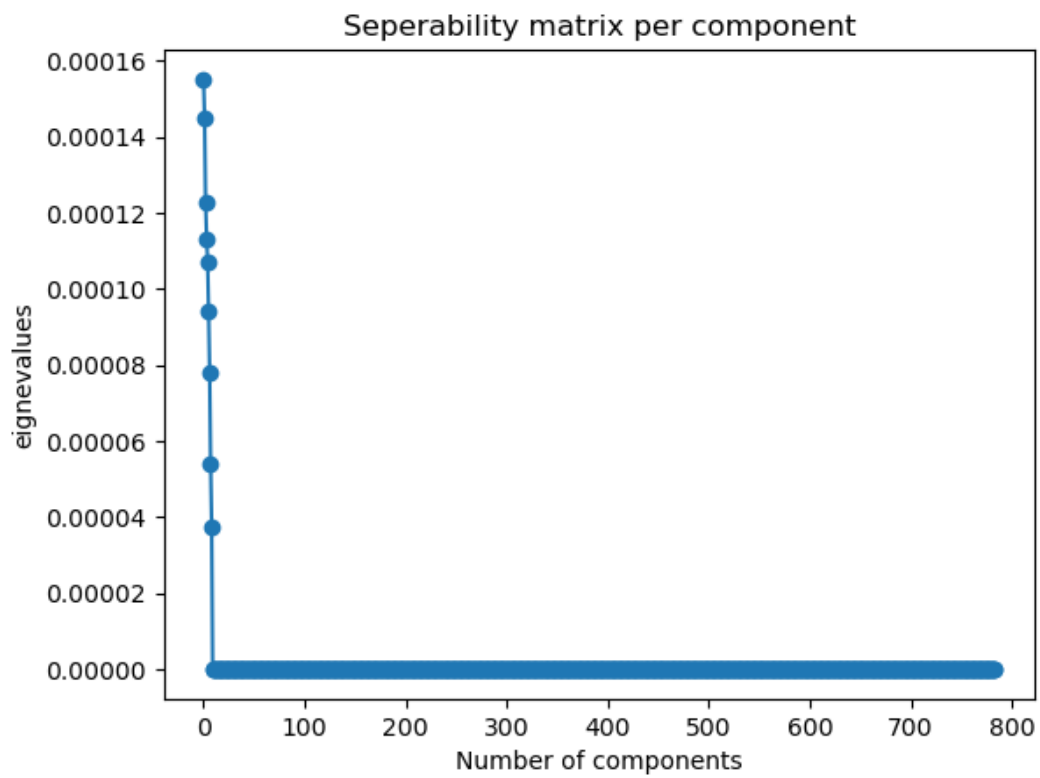
بین کلاسی:

```
[ [ 1.29888889e-05 2.22888889e-05 2.02861111e-04 ... -9.18427778e-03
-3.35802778e-03 -1.51066667e-04 ]
[ 2.22888889e-05 3.37947222e-04 2.31965278e-03 ... 1.08641944e-02
6.06411111e-03 1.30763611e-03 ]
[ 2.02861111e-04 2.31965278e-03 1.98100139e-02 ... -1.20862250e-01
-8.42765556e-02 -3.69195833e-03 ]
...
[ -9.18427778e-03 1.08641944e-02 -1.20862250e-01 ... 5.93001829e+01
1.61146536e+01 1.30130458e+00 ]
[ -3.35802778e-03 6.06411111e-03 -8.42765556e-02 ... 1.61146536e+01
6.90668900e+00 5.64335194e-01 ]
[ -1.51066667e-04 1.30763611e-03 -3.69195833e-03 ... 1.30130458e+00
5.64335194e-01 5.72470583e-02 ] ]
```

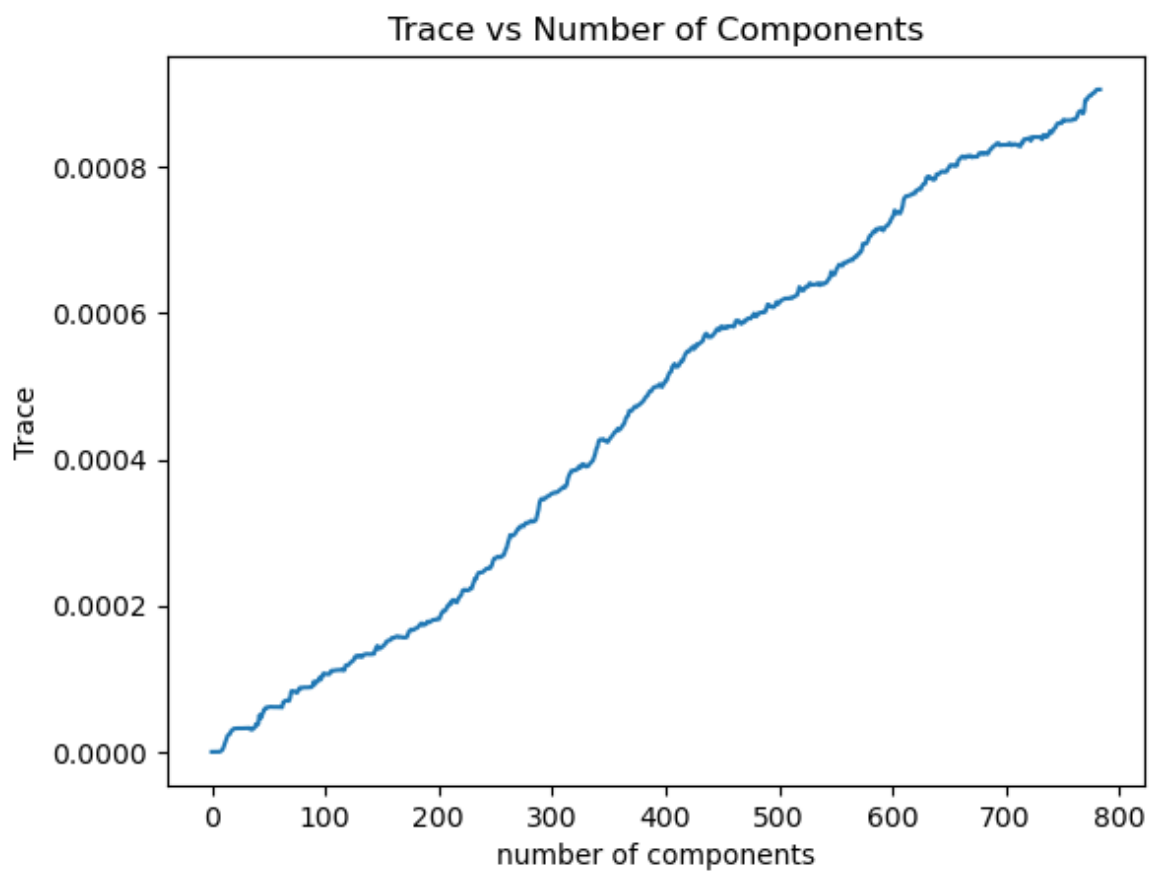
ماتریس جدا پذیر:

```
[ [ 2.13934914e-08 -1.02190875e-08 -3.13146643e-08 ... -8.05114621e-06
-2.39457391e-06 -8.20089262e-08 ]
[ -5.75212111e-09 1.88008271e-08 4.35162725e-08 ... -3.93126223e-06
7.27613772e-07 1.76273832e-07 ]
[ 2.40659769e-09 5.04017094e-09 1.08547239e-07 ... -3.05113466e-07
-1.10193495e-06 -1.80593923e-07 ]
...
[ 1.63087843e-10 -4.05208988e-10 -1.87719999e-09 ... 1.51242469e-07
-3.13233567e-09 -2.58033051e-09 ]
[ -1.13436496e-10 -1.44236991e-09 -6.63855026e-09 ... -6.23108281e-08
-2.46009182e-08 -1.36722401e-08 ]
[ 1.03122389e-10 1.37615825e-09 6.48750320e-09 ... 5.61157138e-07
1.56562554e-07 1.53267886e-08 ] ]
```

ماتریس جدایی پذیر بر تعداد کامپوننت




ب.



با توجه به عکس هرچی تعداد کامپوننت بیشتر می شود تریس ما بزرگتر می شود و این یعنی
پراکندگی بین کلاسی بیشتر و نتایج بهتری بدست میاد از طریق LDA

ابتدا فایل ها را مرتب می کنیم و لیبل بندی می کنیم.

بعد مطابق عکس با دو کامپوننت استفاده کنیم داریم:



مقادیرمون :

covariance matrix : $\begin{bmatrix} 750.50925833 & 268.02257105 \\ 268.02257105 & 973.96356225 \end{bmatrix}$

$\begin{bmatrix} 399.9097764 & 132.02703445 \\ 132.02703445 & 308.16754808 \end{bmatrix}$

ماتریس اول برا داده های آبی و دومی برا قرمز

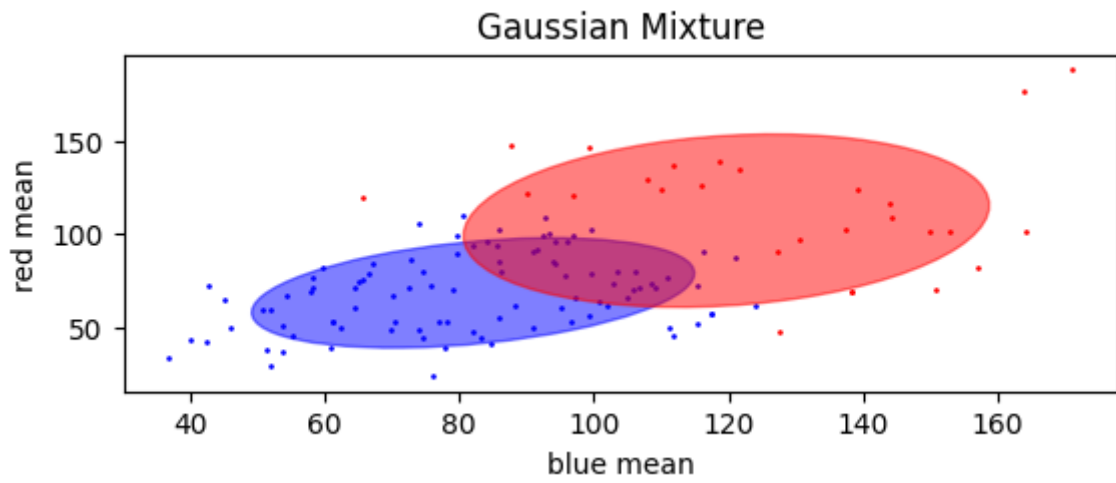
نسبت دو داده:

Weights : [0.55838044 0.44161956]


میانگین رنگ آبی و رنگ قرمز برا داده های آبی و قرمز

mean : $\begin{bmatrix} 106.81416325 & 91.77359052 \\ 73.21415131 & 62.11229303 \end{bmatrix}$

که خروجی نهایی :




حال برای کانکتور داریم





با توجه به عکس می بینیم که هر کدام از نقاط به دو مرکز میانگین آبی یا قرمز بوده اند آن رنگی شدند.

ب

اگر بخواهیم با نمودار BiC و AIC بسنجیم بهترین نقطه برابر با ۴ هست.




که شکل آن



اگر از روش K fold استفاده کنیم و کراس ولیدیشن بزنییم بهترین کامپوننت را ۲ به ما می دهد

best_score = -9.571189380771305



و بقیه نتایج در بالا الف آورده شده است.